

基于深度学习的 A 股短期收益预测与模拟交易

深度学习基础课程大作业实验报告

组员 1: 【待补充: 姓名、学号】 组员 2: 【待补充: 姓名、学号】

分工: 【待补充: 写明两位组员在数据、模型、回测、交易、报告中的具体工作】

2026 年 5 月 22 日

摘要

本文面向课程给定的 A 股日频量价数据, 构建了从数据清洗、特征工程、标签定义、深度学习建模、历史回测到比赛交易辅助的完整流程。项目使用 20 个横截面与时间序列特征, 比较 MLP、LSTM 与 DLinear 三类神经网络模型, 并分别研究日内 mark-to-market 标签 $label_{oc}$ 与严格 A 股 T+1 标签 $label_{oo}$ 。实验按时间划分训练集、验证集与 2025 年回测集, 裁剪和标准化参数只在训练集拟合, 以降低未来信息泄露风险。在严格 T+1 open-to-open 口径下, LSTM seq10 的回测 IC 为 0.03581, ICIR 为 0.42440; 其 Top10 Full 策略总收益为 91.17%, Top10-Drop2 策略在显著降低换手后仍取得 43.71% 总收益。除随机策略外, 本文还给出市场指数基准、交易成本敏感性实验, 以及面向最终模拟交易的每日预测和交易计划工具。由于正式比赛时间为 2026 年 6 月 1 日至 2026 年 6 月 12 日, 本文预留最终模拟交易章节, 赛后补入真实收益、调仓与持仓截图。

关键词: 金融时间序列; LSTM; A 股; T+1; 横截面选股; 历史回测

目录

1	作业要求核对	3
2	问题定义与数据处理	4
2.1	任务定义	4
2.2	数据来源、股票池与时间划分	4
2.3	特征工程	4
2.4	预处理与防泄露设计	5
3	模型与训练方法	5
3.1	模型结构	5
3.2	训练配置	5
4	策略与回测设计	6
4.1	预测指标	6
4.2	交易策略	7

5	实验结果	7
5.1	标签口径对比	7
5.2	严格 T+1 主结果	7
5.3	OC 对照结果与模型比较	8
5.4	市场基准	8
5.5	交易成本敏感性	9
6	实验亮点、局限与思考	9
6.1	实验亮点	9
6.2	局限与反思	10
7	模拟交易方案与赛后预留	10
7.1	比赛执行方案	10
7.2	赛后结果占位	10
7.3	赛后分析写作提示	11
8	结论	11
A	复现材料与输出文件	11
B	提交前检查	12

1 作业要求核对

课程要求报告覆盖数据处理与问题定义、模型实现、训练和历史回测、模拟交易分析，并随代码提交 README.md 与 requirements.txt。表 1 将作业要求与本仓库材料逐项对照。

表 1: 作业要求覆盖情况

要求	当前状态	依据与说明
基础量价数据、股票池说明	已覆盖	使用课程 A 股日频数据，字段含 open/high/low/close/vol/amount，训练与预测均说明剔除北交所股票并尽量过滤 ST 股票。
数据预处理规范	已覆盖	src/data_utils.py 中处理无穷值、缺失样本、训练集分位裁剪和训练集标准化。
无未来信息泄露	已覆盖	时间划分固定为训练、验证、2025 回测三段；裁剪边界、均值和标准差只在训练集拟合，再应用于后续区间。
标签与任务定义	已覆盖	同时定义 $label_{oc}$ 和严格 T+1 的 $label_{oo}$ ，报告明确二者交易时点差别。
深度学习模型	已覆盖	已实现 MLP、LSTM 与 DLinear，主模型为 LSTM seq10；模型代码与训练配置均在仓库中。
训练流程与损失变化	已覆盖	训练脚本、配置、历史损失 CSV 和损失曲线均已保存；图 1 展示主模型损失变化。
基础预测指标	已覆盖	保存并报告 IC、ICIR、RankIC、RankICIR、DirectionAcc。
历史回测	已覆盖	实现 Top10 Full、Top10-Drop2 与 Buffer-Risk 策略，并报告总收益、年化收益、Sharpe、最大回撤、胜率和换手。
结果对比分析	已覆盖	比较模型、标签、随机策略、指数基准和交易成本敏感性。
模拟交易流程	已覆盖待赛后补结果	已实现每日预测、持仓维护、交易计划脚本与 Streamlit 界面；真实收益与截图需在正式比赛结束后补入第 7 节。
组员姓名、学号、分工	待补充	题页已留占位符，提交前必须填写。
源代码可复现材料	已覆盖	仓库包含 requirements.txt、README.md、配置、训练、回测、预测和交易计划代码；课程说明允许不提交原始数据和权重。

2 问题定义与数据处理

2.1 任务定义

本项目不是直接预测股价，而是对每日横截面股票给出未来短期收益预测分数。在信号日 t 收盘后，模型基于当日及历史特征输出每只股票的分数；策略再按照分数排序决定下一交易日的持仓。为区分研究展示口径与真实交易口径，本文使用两套标签：

$$label_{oc}(t) = \frac{close(t+1)}{open(t+1)} - 1, \tag{1}$$

$$label_{oo}(t) = \frac{open(t+2)}{open(t+1)} - 1. \tag{2}$$

$label_{oc}$ 表示第 $t+1$ 日开盘买入后的收盘估值变化； $label_{oo}$ 则表示第 $t+1$ 日开盘买入、至少持有到第 $t+2$ 日开盘卖出的收益，更符合 A 股 T+1 约束。因此本文以 $label_{oo}$ 为最终交易主口径，将 $label_{oc}$ 保留为对照实验。

2.2 数据来源、股票池与时间划分

实验使用课程提供的 A 股日频量价数据。输入基础字段包括股票代码 `ts_code`、交易日 `trade_date`、开高低收价格、前收盘价、成交量和成交额。特征工程后数据约含 747 万条样本、3163 只股票，覆盖 2016 年 2 月至 2026 年 4 月。股票池过滤遵循课程比赛范围：排除北交所股票，并在能够识别股票名称时过滤 ST 股票。

全部实验按时间切分，不做随机打乱：

- 训练集：2019-01-01 至 2023-12-31；
- 验证集：2024-01-01 至 2024-12-31；
- 回测集：2025-01-01 至 2025-12-31。

其中回测集用于更贴近真实执行的历史交易评估，正式模拟交易比赛可视为新的外部测试阶段。

2.3 特征工程

模型使用 20 个核心特征，见表 2。这些特征避免直接依赖不同股票间尺度差异较大的原始价格，同时结合日内结构、短期动量、均线偏离、技术指标、波动率和横截面排名。

表 2: 核心特征分组

类别	特征
横截面排名	close_rank, vol_rank, amount_rank
K 线与量价变化	amplitude, body_ratio, vol_chg, amount_chg
收益与动量	ret_1, ret_5, ret_10, ret_20
均线偏离	rel_ma5, rel_ma10, rel_ma20
技术指标	rsi_14, macd_dif, macd_dea, macd_bar
波动率	vol_std_10, vol_std_20

2.4 预处理与防泄露设计

实现中先将无穷值替换为空值，再删除关键字段缺失样本。分位裁剪与标准化均仅使用训练集估计：特征与标签使用训练集 1% 和 99% 分位裁剪；特征均值和标准差也只由训练集计算。验证集、回测集和每日推理阶段复用同一套预处理状态。LSTM 与 DLinear 的序列样本按股票代码排序后构造滑动窗口，窗口终点为当前信号日，标签也挂在该终点样本上，因此不会把未来价格放入输入特征。

3 模型与训练方法

3.1 模型结构

MLP 基线。 MLP 接收单日 20 维标准化特征，经过多层全连接、BatchNorm、ReLU 与 Dropout 输出一个回归分数。主配置使用隐藏层维度 $512 \rightarrow 256 \rightarrow 128$ ，用于提供简单而有力的非线性基线。

LSTM 主模型。 LSTM 接收形状为 $[batch, seq_len, feature_dim]$ 的序列输入。输入先经过 LayerNorm，再由两层 LSTM 建模时间依赖；最后取最后一个时间步，经 LayerNorm、全连接、ReLU 和 Dropout 输出收益分数。seq10 与 seq20 两种窗口用于比较短窗口与长窗口的效果。

DLinear 对照模型。 DLinear 将序列分解为趋势项和季节项，对时间维度做线性映射，再用特征头输出预测分数。它保留序列结构但归纳偏置更线性，可作为 LSTM 的结构对照。

3.2 训练配置

本文统一使用 Smooth L1 损失、固定随机种子和早停。最终交易主模型的配置见表 3。

表 3: LSTM seq10 严格 T+1 主模型配置

项目	取值
标签	$label_{oo}$
序列长度	10
特征维度	20
LSTM hidden size	128
LSTM 层数	2
Epoch 上限	60
Batch size	32768
学习率	0.001
Weight decay	0.0001
Dropout	0.2
早停耐心	8

图 1 展示了严格 T+1 主模型的训练历史。保存的训练记录表明，训练损失继续下降时验证损失已趋于平稳，因此早停能避免只追逐训练期拟合。




图 1: LSTM seq10 严格 T+1 模型训练与验证损失曲线

4 策略与回测设计

4.1 预测指标

基础预测指标包括日度 IC 均值、ICIR、RankIC、RankICIR 与方向胜率。IC 衡量横截面预测分数与真实收益的线性相关性，RankIC 更关注排序关系；ICIR 则用均值和日度波动的比值评

价信号稳定性。

4.2 交易策略

回测从等权持仓出发，默认目标持仓数为 $n = 10$ ，每日换仓参数为 $k = 2$ ，均在作业建议区间内。实现比较三类策略：

- **Top10 Full**: 每日直接持有预测分数最高的 10 只股票；
- **Top10-Drop2**: 首日买入 Top10，之后仅卖出当前持仓中最低分的 2 只并补入高分股票；
- **Buffer-Risk**: 使用排名缓冲区并加入短期涨跌幅、波动率与流动性近似过滤，限制频繁调仓。

此外对 Top10 策略运行随机分数基准，以检验模型信号是否优于随机选股。严格 T+1 回测把信号日、买入日和卖出日显式分开：

$$signal = t, \quad buy = open(t + 1), \quad sell = open(t + 2).$$

净收益扣除按换手率近似的交易成本，默认费率为 0.0003。

5 实验结果

5.1 标签口径对比

两套标签在全样本上 Pearson 相关系数为 0.84468，Spearman 相关系数为 0.91707；每日横截面 Spearman 均值也达到 0.90766。这说明二者都刻画短周期收益排序，但并不等价。 $label_{oo}$ 的标准差为 0.03238，高于 $label_{oc}$ 的 0.02632，反映出跨夜持有引入了额外波动。严格 T+1 报告应以 $label_{oo}$ 为主，而不能只展示更乐观的日内估值收益。

5.2 严格 T+1 主结果

表 4 给出 2025 年严格 T+1 回测区间预测指标。LSTM seq10 在 ICIR 与 RankICIR 上稳定领先，因此被选为比赛阶段主模型。

表 4: 严格 T+1 真实执行预测指标

模型	IC	ICIR	RankIC	DirectionAcc
MLP	0.04019	0.33985	0.03096	0.50497
LSTM seq10	0.03581	0.42440	0.04112	0.51145
LSTM seq20	0.02989	0.37405	0.03267	0.50371
DLinear seq10	0.00868	0.12944	0.01622	0.49135
DLinear seq20	0.01186	0.12960	0.02064	0.49131

表 5: LSTM seq10 严格 T+1 策略回测

策略	总收益	年化收益	Sharpe	最大回撤	平均换手
Top10 Full	91.17%	102.15%	2.60	-14.89%	1.5302
Buffer-Risk	54.79%	60.74%	1.97	-14.53%	0.5983
Top10-Drop2	43.71%	48.27%	1.62	-16.58%	0.4026
Random Top10-Drop2	27.63% $\pm$ 14.48%	30.42% $\pm$ 16.12%	1.23 $\pm$ 0.49	-17.92%	0.4026
Random Top10 Full	12.10% $\pm$ 12.20%	13.27% $\pm$ 13.41%	0.63 $\pm$ 0.52	-18.26%	1.9890

图 2 显示严格 T+1 回测中的净值与回撤。Top10 Full 收益最高，但平均换手超过 1.5；Top10-Drop2 降低换手后仍优于对应随机基准，更适合在短期比赛里兼顾信号利用与执行成本。




图 2: LSTM seq10 严格 T+1 回测曲线

5.3 OC 对照结果与模型比较

$label_{oc}$ 口径保留为研究对照。LSTM seq10 的 OC 回测 IC 为 0.02340、ICIR 为 0.26272；Top10 Full 总收益为 183.77%，Top10-Drop2 总收益为 172.62%。这些收益高于 OO 结果，但其收益定义包含买入当日收盘估值，因此不直接代表 T+1 可卖出的实现收益。综合两套标签可见：MLP 是稳健的单日特征基线，LSTM seq10 能更好利用短历史窗口，而 DLinear 在本任务上的信号和策略收益均较弱，适合作为线性序列对照而非最终交易模型。

5.4 市场基准

表 6 使用 2025 年主要指数基准做横向比较。严格 T+1 的 LSTM seq10 Top10 Full 与 MLP Buffer-Risk 均高于三类指数；低换手 LSTM seq10 Top10-Drop2 高于上证指数和沪深 300，但低于创业板指。

表 6: 2025 年指数基准

指数	总收益	年化收益	Sharpe	最大回撤
上证指数	21.65%	22.53%	1.60	-9.71%
沪深 300	21.19%	22.06%	1.41	-10.49%
创业板指	55.46%	58.02%	1.72	-20.79%

5.5 交易成本敏感性

短期横截面策略容易把预测优势换成高换手。表 7 将费率从 0.0003 提高到 0.003。Top10 Full 在高费率下快速退化，费率 0.003 时总收益转为 -26.44%；Top10-Drop2 因平均换手较低仍保留 12.00% 总收益。因此最终模拟交易默认采用 LSTM seq10 OO + Top10-Drop2，而不是只追求最低费率下的最高收益。

表 7: 主策略交易成本敏感性

策略	Fee	总收益	年化收益	Sharpe	平均换手
LSTM OO Top10 Full	0.0003	91.17%	102.15%	2.60	1.5302
LSTM OO Top10 Full	0.0010	49.30%	54.54%	1.65	1.5302
LSTM OO Top10 Full	0.0030	-26.44%	-28.36%	-1.05	1.5302
LSTM OO Top10-Drop2	0.0003	43.71%	48.27%	1.62	0.4026
LSTM OO Top10-Drop2	0.0010	34.72%	38.22%	1.35	0.4026
LSTM OO Top10-Drop2	0.0030	12.00%	13.10%	0.58	0.4026

6 实验亮点、局限与思考

6.1 实验亮点

1. 将日内估值标签与严格 T+1 open-to-open 标签分开，避免用不可直接落地的收益定义掩盖交易约束。
2. 在模型之外比较策略、随机基准、指数基准和交易成本，使实验从预测指标延伸到实际执行质量。
3. 使用同一特征体系对比 MLP、LSTM 和 DLinear，既保留课程神经网络主线，也能解释主模型选择。
4. 增加每日预测脚本、交易计划脚本与 Streamlit 界面，能够用最新盘后数据生成比赛候选并维护真实持仓。

6.2 局限与反思

历史回测仍是现实交易的近似。本文显式考虑手续费近似与 $T+1$ 时间约束，但未完整建模涨跌停、停牌、最小成交单位和实际委托未成交。此外，预测指标与最终收益并非单调关系：DLinear 的部分验证指标可为正，但策略表现仍弱；Top10 Full 历史收益更高，却对成本更敏感。这说明金融任务不能只根据单一 loss 或单一收益表选模型，还需要关注标签口径、排序稳定性、换手与执行可行性。

7 模拟交易方案与赛后预留

7.1 比赛执行方案

正式模拟交易期间默认采用 LSTM seq10 OO 主模型和 Top10-Drop2 策略。每日在信号日盘后同步最新行情，复用训练期 checkpoint 与预处理状态生成候选分数；交易日按计划先处理卖出，再补入高分股票，尽量维持满仓并遵守 $T+1$ 。若 Streamlit 页面可用，则用页面维护 data/current_positions.csv、生成买入/卖出/持有清单；若页面不可用，则调用 src/predict_daily.py 与 src/make_trade_plan.py 完成相同流程。

7.2 赛后结果占位

本节必须在比赛结束后补齐，提交前请不要删除该提醒。

表 8: 模拟交易结果汇总占位表

项目	赛后填写
比赛区间	2026-06-01 至 2026-06-12
所用模型与策略	LSTM seq10 OO + Top10-Drop2，若中途调整请说明原因
初始资产与期末资产	【待补充：填入同花顺模拟盘结果】
区间收益率	【待补充：填入最终收益】
调仓次数与主要异常	【待补充：记录未成交、涨跌停、持仓偏离等情况】
与模型计划的一致性	【待补充：说明实际下单是否遵循每日候选与交易计划】

在此插入收益趋势截图

建议文件：report/figures/simulation_equity.png

在此插入调仓记录截图

建议文件: `report/figures/simulation_trades.png`

在此插入持仓记录截图

建议文件: `report/figures/simulation_positions.png`

7.3 赛后分析写作提示

赛后分析建议回答三点：第一，真实收益与历史回测预期是否一致；第二，成交限制和满仓要求如何影响计划执行；第三，短期比赛噪声下哪些经验可以反馈到标签、策略或风险控制设计。这些内容直接对应作业中“收益记录、过程经验、感悟和思考”的评分要求。

8 结论

本文完成了课程要求的主体实验闭环：以课程 A 股量价数据为基础，构建可防泄露的时间切分和训练集预处理流程，实现多种神经网络模型、历史回测、策略对照和每日交易辅助工具。从严格 T+1 结果看，LSTM seq10 在预测稳定性和策略收益之间表现最好；在考虑成本后，低换手 Top10-Drop2 是更适合模拟交易阶段的默认方案。最终提交前仍需补齐组员信息、分工和正式比赛的真实截图与收益分析。

A 复现材料与输出文件

代码仓库中与报告直接对应的主要文件如下：

- 数据预处理: `src/data_utils.py`;
- 模型定义: `src/model.py`, `src/model_lstm.py`, `src/model_dlinear.py`;
- 训练脚本: `src/train_mlp.py`, `src/train_lstm.py`, `src/train_dlinear.py`;
- 严格 T+1 回测: `src/robust_backtest_t1_all_models.py`;
- 每日交易辅助: `src/predict_daily.py`, `src/make_trade_plan.py`, `src/trading_dashboard.py`;
- 主模型结果: `outputs_lstm_seq10_oo_e60/t1_backtest/`;
- 指数与成本敏感性: `outputs_benchmark/index/` 与 `outputs_benchmark/fee_sensitivity/`。

B 提交前检查

1. 填写封面的两位组员姓名、学号 and 具体分工。
2. 比赛结束后补入第 7 节的收益、调仓、持仓截图与文字分析。
3. 保留 `requirements.txt`、`README.md`、全部源码和本报告源文件。
4. 根据课程要求打包代码和报告：原始数据与模型权重可不随压缩包提交，但报告需说明数据来源。